Università degli Studi di Verona

CORSO DI LAUREA IN INFORMATICA

Fondamenti dell'Informatica

Federico Brutti
federico.brutti@studenti.univr.it

Inserire citazione inerente alla materia

Contents

1 Introduzione **3**
- 1.1 Storia dell'informatica . . . 3
- 1.2 Contestualizzazione . . . 4
- 1.3 Problema dell'Informatica . . . 5
- 1.4 Concetti di base richiesti . . . 6

2 Linguaggi formali e automi **7**
- 2.1 Linguaggi formali . . . 7
- 2.2 Automi a stati finiti . . . 7
  - 2.2.1 Automi a stati finiti deterministici . . . 8
  - 2.2.2 Automi a stati finiti non deterministici . . . 11
  - 2.2.3 NFA con epsilon transizioni . . . 13

3 Linguaggi regolari **14**
- 3.1 Operazioni ed espressioni regolari . . . 14
- 3.2 Proprietà principali dei linguaggi regolari . . . 17
- 3.3 Teorema di Myhill-Nerode . . . 17
- 3.4 Pumping lemma per linguaggi regolari . . . 20

4 Linguaggi liberi da contesto **22**
- 4.1 Linguaggi liberi da contesto, forme normali e automi a pila . . . 22
- 4.2 Classificazione di Chomsky . . . 22

5 Teoria della calcolabilità **23**
- 5.1 Meet and fuck kingdom, steve . . . 23
- 5.2 Meet 'n HUH!? . . . 23

Chapter 1

Introduzione

1.1 Storia dell'informatica

L'**informatica**, abbreviazione di informazione automatica è una scienza nata negli anni '60 dalla fusione di vari aspetti scientifici e ingegneristici. In particolare ha un'origine **matematica**, dove si è definito che cosa sia "calcolare", e una **tecnologica**, determinante gli strumenti utilizzati per il calcolo. Quest'ultimo, nel senso moderno, nasce nell'epoca dell'Illuminismo ed è dovuto, in ambito del Determinismo, alla necessità di approssimare logaritmi e funzioni trigonometriche mediante polinomi, ottenendo un risultato univoco a partire da date condizioni iniziali.

Formalizzate queste tecniche nel '700, si vide successivamente la necessità di **meccanizzare** il calcolo. Il primo strumento funzionante fu la **macchina analitica**, creata da Charles Babbage e Ada Lovelace nel 19° secolo; proponeva un concetto rivoluzionario: la possibilità di programmazione per poter ritornare risultati in base ai parametri forniti. Poteva essere usata per sviluppare qualsiasi funzione di complessità e generalità arbitrarie, ripetendo operazioni sugli stessi elementi.

Le origini matematiche dell'informatica ebbero invece luogo con la necessità di verificare se la matematica fosse formalizzabile come insieme finito non contraddittorio di assiomi. Ciò non è possibile, perché ci si scontra inevitabilmente con le contraddizioni e gli assurdi. L'effettivo limite di ciò che è calcolabile e non fu definito con il **teorema di incompletezza** di Gödel; la restrizione del range di studio fu fondamentale per avere un'idea più chiara del dominio operativo. Andando avanti con gli anni, Alan Turing ideò l'omonima macchina, la cui idea principale era la possibilità interpretare il **calcolo** come sequenza anche infinita di sostituzioni di simboli: un algoritmo. Questo era naturalmente un programma finito dove ogni passo dipende da altrettante informazioni finite. Separa inoltre il controllo dalla memoria, ponendo le basi per quello che sarebbero diventati i calcolatori moderni. Oltre a ciò, insieme a Church definì la **Tesi di Church-Turing**, la quale afferma che se un problema è intuitivamente calcolabile, allora esisterà una

macchina di Turing (MDT) o un dispositivo equivalente[1] in grado di risolverlo, ovvero calcolarlo. L'ambito di studio dell'informatica è interamente incluso nell'insieme delle funzioni calcolabili, ovvero i problemi, le cui soluzioni sono fornite dagli algoritmi.

1.2 Contestualizzazione

Studiare la teoria della ricorsione e della calcolabilità è utile per fornire consapevolezza in merito ai limiti logici assoluti; insegna in primo luogo a riconoscere problemi impossibili, fornisce un criterio per capire quando fermarsi e permette di partire da assunzioni più chiare durante lo sviluppo software.

Tutte queste competenze sono in ogni caso usate durante il **calcolo**, formalmente definito come la risoluzione di un problema tramite un algoritmo, indipendentemente da quanto tempo o spazio è richiesto per la computazione. Come già menzionato, tuttavia, non sarà sempre possibile trovare una soluzione per ogni problema proposto, anche se formalmente definibile; per questa ragione, in termini pratici, non esistono programmi che verifichino la correttezza assoluta o la sicurezza di un dato software. Ciò che più si avvicina allo scenario di controllo ideale è l'**analisi del software**, ovvero la verifica del comportamento del programma in base a ciò che ci si aspetta. In particolar modo bisogna garantire:

- **Affidabilità**: Il software non deve andare in crash improvvisamente.
- **Sicurezza**: Il software, interfacciandosi con utenti esterni, non deve essere violato o manipolato.
- **Protezione**: Il software, se in controllo di sistemi critici, non deve causare incidenti.

Idealmente, dato un qualunque software con una data proprietà di interesse, esisterebbe un programma di analisi atto al calcolo automatico e preciso del soddisfacimento della stessa in tempo finito: il debugger ideale. Tuttavia, non è realistico che esista, poiché non abbiamo modo di verificare a priori se un programma termini o meno; in altre parole non può esistere:

$$\text{Per ogni programma } p \in \mathbb{L},\ \text{halt}(p) = \text{true} \iff p \text{ termina}$$

Ciò vale anche per un eventuale programma antivirus ideale, che segnalerebbe correttamente ogni malware nel caso in cui i relativi programmi in questione eseguissero compiti malevoli, come rubare o cifrare i dati. Questo perché non è possibile creare un algoritmo universale per un'analisi infallibile; tenendo a mente la definizione appena discussa, supponiamo un malware M che esegue un secondo programma P su un dato input x: se $P(x)$

[1] Strumenti come lambda-calcolo, funzioni ricorsive o linguaggi di programmazione turing completi.

termina, un file viene rimosso, altrimenti non arriva mai alla cancellazione. Non potendo sapere se un programma termini a priori, non sarà altrettanto possibile segnalarlo come malware, mostrando il limite logico.

Ancora più difficile sarebbe dimostrare che un software sta agendo in modo malevolo quando il discriminante è una proprietà semantica non banale, come la cifratura dei dati, nel caso dei ransomware. Da ciò, il **Teorema di Rice**: non esiste un algoritmo tale che per ogni programma sia capace di decidere automaticamente una proprietà semantica non banale, come per esempio la terminazione, fornire un risultato specifico, o determinare se due computazioni siano equivalenti.

Ciò non significa che tutto sia precluso; bisogna accettare i limiti imposti dall'insieme dei problemi calcolabili per lavorare esclusivamente su questi ultimi. In questi termini, non sarà possibile avere analisi automatiche corrette e complete, come anche ottenere risposte sempre precise, data dalla possibilità del verificarsi di falsi negativi e positivi. In ogni caso, esistono più iter di lavoro per l'analisi del software:

- **Model checking**: Controllo esaustivo di un modello del programma da analizzare.
- **Analisi statica**: Controllo automatico ed esaustivo sul programma senza che venga eseguito.
- **Testing**: Verifica di un sottoinsieme delle esecuzioni del sistema.
- **Antivirus firma e sandbox**: Sistema difensivo probabilistico, vulnerabile a stealthing.

1.3 Problema dell'Informatica

Prima di definire formalmente il problema che l'Informatica si pone di risolvere, è necessario chiarire alcuni concetti preliminari: sappiamo in primo luogo che il dominio di lavoro è un sottoinsieme dell'insieme dei numeri naturali $\mathbb{N}$ contenente le funzioni calcolabili, le quali sono definite come un insieme di coppie appartenenti alle parti di $\mathbb{N}$, ovvero:

$$f \in \mathcal{P}(\mathbb{N} \times \mathbb{N})$$

Per conoscere quante sono le funzioni del suddetto dominio, quindi la **cardinalità** dell'insieme $\mathcal{P}(\mathbb{N} \times \mathbb{N})$, notiamo che il numero di elementi all'interno di $\mathbb{N} \times \mathbb{N}$ ed $\mathbb{N}$ è equivalente e come conseguenza diretta sono entrambi numerabili e ordinabili. In questi termini esiste quindi una biezione univoca tra i due insiemi, ovvero che a ogni input corrisponde un output. La cardinalità dell'insieme delle parti $\mathcal{P}(\mathbb{N} \times \mathbb{N})$ sarà a sua volta equivalente a quella delle funzioni $\mathbb{N} \times \mathbb{N}$, dimostrando che esistono tante funzione quanti sottoinsiemi di $\mathbb{N}$.

Si ritiene ora necessario capire quanti algoritmi risolutivi esistano, definiti in termini logici come sequenze di simboli su un alfabeto Σ, il quale deve essere finito e non vuoto; esisteranno quindi tanti programmi quante sono le stringhe componibili con il suddetto alfabeto, il cui insieme è indicato con Σ^*. Per esempio:

$$\Sigma = \{a, b\} \implies \Sigma^* = \{\epsilon, a, b, aa, ab, ba, bb, aaa, ...\}$$

Dove ϵ rappresenta la stringa vuota. Si tratta di un insieme ordinabile privo di un limite superiore e in quanto tale può essere messo in relazione con quello dei naturali; ne concludiamo che:

$$|\Sigma^*| = |\mathbb{N}|$$

Dunque la cardinalità dell'insieme degli algoritmi è equivalente a quella dell'insieme dei naturali. Inoltre, per il **teorema di Cantor**, si può dimostrare come l'insieme delle parti avrà sempre cardinalità maggiore rispetto a quello intero; per esempio:

$$S = \{a, b\} \implies \mathcal{P}(S) = \{\{a\}, \{b\}, \emptyset, \{a, b\}\} \implies |S| = 2; |\mathcal{P}(S)| = 4$$

1.4 Concetti di base richiesti

Chapter 2

Linguaggi formali e automi

2.1 Linguaggi formali

Per **linguaggio formale** intendiamo un insieme di stringhe composte da simboli di un alfabeto Σ, definito come un insieme non vuoto di questi ultimi.

In particolare, un **simbolo** è un'entità primitiva astratta non definita formalmente, come lettere e cifre; una loro sequenza finita è detta **stringa**, la quale avrà una **lunghezza** $|w|$ che indica il numero di occorrenze di simboli che la compongono, per esempio:

$$abbba \implies |w| = 5$$

In questi termini è necessario notare come l'ambito di questa materia sarà tradurre il calcolo delle funzioni in relazioni di insieme. Esistono diversi tipi di linguaggi:

- **Linguaggio finito**: Composto da sole costanti, non richiede alcuna memoria e non ci sono input sconosciuti.
- **Linguaggio regolare**: Si traduce in una funzione lineare per la quale serve memoria, ma di quantità finita necessaria per calcolarla.
- **Linguaggio context free**: Non è conosciuta la quantità di memoria richiesta per calcolare la funzione, richiede una stack.
- **Linguaggio decidibile**: Funzione per la quale la stack non è sufficiente e si richiede ulteriore memoria a supporto.

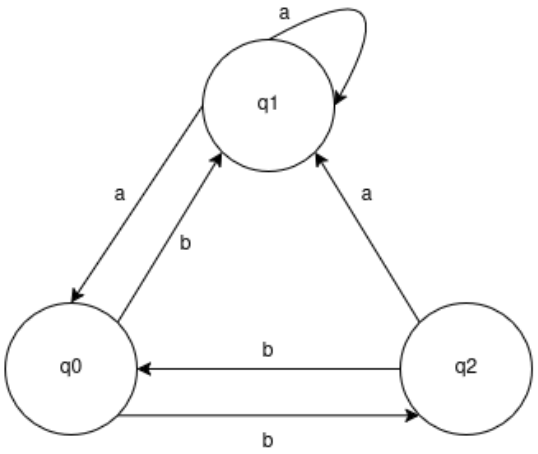
2.2 Automi a stati finiti

Un **Automa a stati finiti** è il modello di un sistema avente input e un eventuale output a valori discreti. Il sistema può trovarsi in uno stato all'interno di un loro insieme finito

e ciò gli consente di tenere traccia della storia precedente, quindi di avere una memoria finita.

Questi modelli sono rappresentabili mediante una testina che legge un nastro di lunghezza illimitata contenente i simboli. In base allo stato corrente q e del simbolo letto s_i, la testina vedrà se spostarsi in un altro stato o meno, e leggerà il simbolo successivo. Alla terminazione della lettura, in base allo stato raggiunto, l'automa fornirà un risultato di accettazione o rifiuto della stringa letta.

Il comportamento degli automi è definito univocamente con una tabella chiamata **matrice di transizione**, e sono rappresentati con il seguente grafo:



	a	b
q0	q1	q2
q1	q1	q0
q2	q1	q0

Figure 2.1: Esempio di automa a stati finiti

2.2.1 Automi a stati finiti deterministici

Gli Automi a stati finiti deterministici (DFA) sono una sottoinsieme di automi, definiti come una quintupla $M = (Q, \Sigma, \delta, q_0, F)$, i cui elementi sono:

- Q: Insieme finito degli stati.
- Σ: Alfabeto dei simboli che l'automa può riconoscere.
- $\delta : Q \times \Sigma \to Q$: Funzione di transizione degli stati, la quale, data una coppia (stato, simbolo), ritorna lo stato successivo.
- q_0: Stato iniziale dell'automa.
- $F \subseteq Q$: Insieme degli stati finali che descrive i risultati accettabili ottenibili dall'automa.

Dalla funzione di transizione δ si ottiene anche in modo univoco quella che descrive lo stato raggiunto dopo aver letto una sequenza di simboli $\hat{\delta} : Q \times \Sigma^* \to Q$ nel seguente modo:

$$\begin{cases} \hat{\delta}(q, \epsilon) = q \\ \hat{\delta}(q, \omega a) = \delta(\hat{\delta}(q, w)a) \end{cases}$$

Questa funzione è detta **chiusura transitiva di** δ; nel primo caso l'automa non legge nulla, mentre nella seconda espressione si indica che ha letto una sequenza di caratteri e un nuovo simbolo annotato con a.

Tuttavia, menzionando la possibilità di ritornare un risultato di non accettazione, ne consegue che esistano dei simboli (e di conseguenza, linguaggi), non riconoscibili dall'automa. Questa caratteristica è il discriminante che consente di definire i **linguaggi regolari**: tali se e solo se esiste un automa a stati finiti deterministico M che lo riconosce. Vengono definiti come:

$$L_m = \{\sigma \in \Sigma^* | \hat{\delta}(q_0, \sigma) \in F\}$$

L'insieme dei linguaggi caratterizzati dall'essere riconosciuti da un DFA è detto **insieme dei linguaggi regolari**, e per dimostrare che un linguaggio L gli appartiene è necessario fornire un DFA capace di riconoscerlo correttamente. Per esempio, supposto l'alfabeto $\Sigma = \{a, b\}$ e il linguaggio $\emptyset$, viene generato il seguente automa:

$$M_\emptyset = \langle \{q_0\}, \{a, b\}, \delta, q_0, \emptyset \rangle$$

Affermando che $\emptyset = L_m$, otteniamo:

$$L_m = \{\sigma \in Sigma^* | \hat{\delta}(q_0, \sigma) \in F\}$$

Semanticamente parlando, notiamo che è impossibile che l'automa si muova se non legge niente, infatti l'espressione $\hat{\delta}(q_0, \sigma) \in F$ è sempre falsa, definendo il corretto comportamento dell'automa quando non accade niente e provando che $\emptyset$ è un linguaggio regolare. Supponiamo ora un linguaggio di stringhe che contengono almeno due '1' sull'alfabeto $\Sigma = \{0, 1\}$, quindi:

$$L = \{x \in \Sigma^* | x \text{contiene due '1'}\}$$

Costruiamo un automa M a tre stati definito dalla seguente matrice di transizione:

	$i = 0$	$i = 1$
q_0	q_0	q_1
q_1	q_1	q_2
q_2	q_2	q_2

Table 2.1: Matrice di transizione

Questo deve riconoscere il linguaggio, il quale deve essere $L = L(m)$, che è equivalente a dire $L \subseteq L(m) \wedge L(m) \subseteq L$, ovvero tutto il linguaggio è riconosciuto da M e il linguaggio riconosciuto da M è contenuto in L. Dimostriamo le due tesi:

- $L \subseteq L(m) \iff \forall x \in \Sigma^*.x \in L \implies x \in L(m) \implies \hat{\delta}(q_0, x) \in F$

  Dunque per ogni stringa componibile con Σ^* è necessario che si riesca ad arrivare a uno stato finale.

- $L(m) \subseteq L \iff x \in L(m) \implies x \in L$

  Ovvero la stringa del linguaggio formale deve essere anche contenuta in quello che si vuole dimostrare tale.

Notare che per la seconda dimostrazione, la prima tesi vale se e solo se si riesce ad arrivare a uno stato finale con la stringa x, necessariamente contenuta in L. Poste queste basi per il linguaggio, possiamo procedere a dimostrare la regolarità di L per induzione sulla lunghezza di x, mostrando che:

$$\begin{cases} x \in L \implies \hat{\delta}(q_0, x) \in F \\ x \notin L \implies \hat{\delta}(q_0, x) \notin F \end{cases}$$

Passo base: $|x| = 0 \iff x = \epsilon$

Bisogna prendere la più piccola lunghezza che garantisca sia stringhe in L che stringhe ad esso non appartenenti. $|x| = 2$ è sufficiente. Procediamo a dimostrare la base per ogni lunghezza fino a due:

- $|x| = 0$:

$$\hat{\delta}(q_0, x) = \hat{\delta}(q_0, \epsilon) = q_0 \notin F$$

- $|x| = 1$:

$$\begin{cases} x = 0 \notin L & \implies \hat{\delta}(q_0, 0) = \delta(q_0, 0) = q_0 \notin F \\ x = 1 \notin L & \implies \hat{\delta}(q_0, 1) = \delta(1_0, 1) = q_1 \notin F \end{cases}$$

- $|x| = 2$:

$$\begin{cases} x = 00 \notin L & \implies \hat{\delta}(q_0, x) = q_0 \notin F \\ x = 01 \notin L & \implies \hat{\delta}(q_0, x) = q_1 \notin F \\ x = 10 \notin L & \implies \hat{\delta}(q_0, x) = q_1 \notin F \\ x = 11 \in L & \implies \hat{\delta}(q_0, x) = \delta(\hat{\delta}(q_0, 1), 1) = \delta(q_1, 1) = q_2 \in F \end{cases}$$

Questa è la definizione formale della base, per cui si dice che ogni stringa di lunghezza uguale a 2 che non contiene due cifre '1' non è accettata all'interno del linguaggio.

Passo induttivo: Sempre in riferimento alla lunghezza della stringa, è necessario dimostrare che per $|z| = n + 1$ valga la seguente ipotesi induttiva: sia $n \in N$; $\forall x.|x| \leq n$:

$$\begin{cases} x \in L \implies \hat{\delta}(q_0, x) \in F \\ x \notin L \implies \hat{\delta}(q_0, x) \notin F \end{cases}$$

Con una lunghezza della stringa non ben definita, è possibile che si abbiano $x = x'0$ oppure $x = x'1$, dipendentemente da cosa l'automa legge. Definiamo i casi:

- $x' \in L \implies x \in L$ per definizione, e per ipotesi induttiva porta allo stato finale:

$$\hat{\delta}(q_0, x') = q_2$$

- Se $x' \notin L$ e $x = x'1$ l'automa ha letto almeno una cifra '1'. Bisogna leggere il seguente simbolo. Se x' contiene '1', allora $x \in L$, altrimenti $x \notin L$.

- Se $x' \notin L$ e $x = x'0$ l'automa non ha ancora letto una cifra '1'; in questi termini non è possibile raggiungere uno stato finale, quindi varrà $x \notin L$ a prescindere dalla lettura di $x'0$ o $x'1$. Dunque:

$$\hat{\delta}(q_0, x) = \delta(\hat{\delta}(q_0, x'), 0) \in \{q_0 q_1\} \nsubseteq F$$

2.2.2 Automi a stati finiti non deterministici

Un automa a stati finiti non deterministico (NFA), similmente al precedente, è una quintupla $M = \langle Q, \Sigma, \delta, q_0, F \rangle$, dove Q, Σ, q_0 ed $F \subseteq Q$ mantengono il precedente significato, mentre la funzione di transizione diventa:

$$\delta : Q \times \Sigma \to \mathcal{P}(Q)$$

Notare che ora è possibile accettare un numero maggiore di linguaggi, siccome δ è ora capace di ritornare un insieme di stati; per esempio è ammesso $\delta(q, a)$ per qualche $q \in Q$ e $a \in \Sigma$. Come conseguenza diretta, anche la chiusura transitiva subisce la stessa variazione, ed è ottenibile nel modo seguente:

$$\begin{cases} \hat{\delta}(q, \epsilon) = \{q\} \\ \hat{\delta}(q, \omega a) = \cup_{p \in \hat{\delta}(q, \omega)} \delta(p, a) \end{cases}$$

Per costruzione, è inoltre permesso che la $\delta(q, a) = \emptyset$, perché è un elemento appartenente all'insieme delle parti di Q. Una stringa x è invece accettata se l'intersezione tra la funzione $\hat{\delta}(q_0, x)$ e l'insieme degli stati finali F non è vuota; in questi termini, la definizione del linguaggio accettato da questi automi è:

$$L(M) = \{x \in \Sigma^* : \hat{\delta}(q_0, x) \cap F \neq \emptyset\}$$

La rappresentazione grafica degli NFA mediante grafo non cambia, ma la matrice di transizione, dato il non determinismo, richiede che sia indicato un insieme di stati raggiungibili. Supponiamo per esempio un NFA dalle seguenti caratteristiche:

- $Q = \{q_0, q_1, q_2\}$
- $\Sigma = \{0, 1\}$
- Stato iniziale q_0
- Insieme stati finali $F = \{q_2\}$

E che bisogni verificare se ammette il linguaggio $L = \{x \in \Sigma^* | x \text{ contiene almeno due '1'}\}$. La dimostrazione fa uso del teorema di **Rabin-Scott**, il quale afferma che dato un NFA M, esisterà un DFA M' tale per cui valga $L(M) = L(M')$, ovvero che il linguaggio sia accettato da entrambi.

Questo enunciato si basa sul fatto che i DFA si possano vedere come casi particolari di NFA in cui la funzione di transizione restituisce sempre insiemi costituiti da un solo stato. Dunque:

$$M = \langle Q, \Sigma, \delta, q_0, F\rangle \implies M' = \langle Q', \Sigma, \delta', q_0', F'\rangle \text{ tale che } L(M) = L(M')$$

Si vuole quindi costruire M' a partire da M, il quale sarà composto da:

- $Q' = \mathcal{P}(Q)$: Insieme delle parti degli stati di M.
- $q_0' = \{q_0\}$: Stato iniziale per entrambi gli automi.
- $F' = \{P \subseteq Q | P \cap F \neq \emptyset\}$: Insieme di stati di M' che contengono almeno uno stato finale di M.
- $\delta'(P, a) = \cup_{p \in P} \delta(p, a)$: Funzione di transizione che determina tutti gli stati raggiungibili.

Per dimostrare il teorema è necessario provare che il linguaggio è riconosciuto da entrambi gli automi, usando l'induzione sulla lunghezza della stringa di input x, tale che:

$$\hat{\delta}(q_0, x) = \hat{\delta'}(q_0', x)$$

Per $|x| = 0$ si ha un risultato banale, poiché per costruzione abbiamo $q_0' = \{q_0\}$ e una stringa vuota $x = \epsilon$. Ragioniamo quindi sul passo induttivo e diciamo che l'ipotesi valga per ogni x tale per cui $|x| \leq m$. Considerando xa una stringa di lunghezza $m+1$, avremo:

$$\begin{aligned}
\hat{\delta'}(q_0', xa) &= \delta'(\hat{\delta'}(q_0', x), a) && \text{Definizione di } \hat{} \text{ nei DFA} \\
&= \delta'(\hat{\delta}(q_0, x), a) && \text{Per ipotesi induttiva} \\
&= \cup_{p \in \hat{\delta}(q_0, x)} \delta(p, a) && \text{Definizione di } \delta' \\
&= \hat{\delta}(q_0, xa) && \text{Definizione di } \hat{} \text{ nei NFA}
\end{aligned} \tag{2.1}$$

L'enunciato del teorema segue dal fatto che:

$$\begin{aligned} x \in L(M) &\iff \hat{\delta}(q_0, x) \cap F \neq \emptyset && \text{Definizione linguaggio NFA} \\ &\iff \hat{\delta'}(q'_0, x) \cap F \neq \emptyset && \text{Proprietà dei NFA} \\ &\iff \hat{\delta'}(q'_0, x) \in F' && \text{Definizione di } F' \\ &\iff x \in L(M') && \text{Definizione linguaggio DFA} \end{aligned} \tag{2.2}$$

2.2.3 NFA con epsilon transizioni

Esistono ulteriori automi capaci di cambiare stato senza che debbano leggere alcun simbolo, gli automi a stati finiti non deterministici con ϵ-transizioni (ϵ-NFA), per i quali bisogna capire se questa loro caratteristica cambi la classe dei linguaggi riconoscibili. Sono anch'essi definiti come una quintupla:

$$N = \langle Q, \Sigma, \delta, q_0, F \rangle$$

I cui elementi sono tutti uguali a quelli degli NFA, eccezion fatta per la funzione di transizione e relativa chiusura transitiva:

$$\delta : Q \times (\Sigma \cup \{\epsilon\}) \to \mathcal{P}(Q); \quad \hat{\delta} : Q \times \Sigma^* \to \mathcal{P}(Q)$$

Dalla definizione è chiaro che accetta ogni simbolo dell'alfabeto Σ e anche una stringa vuota. Tuttavia è necessario distinguere l'insieme di tutti quelli stati raggiungibili senza leggere simboli. Definiamo quindi:

- ϵ-closure(q): Insieme degli stati raggiungibili seguendo archi con simboli ϵ dell'automa.
- ϵ-closure $Q \to \mathcal{P}(Q)$: Funzione di transizione degli stati senza leggere simboli.

Le cui chiusure transitive sono definite con:

$$\begin{cases} \hat{\delta}(q, \epsilon) & = \epsilon - closure(q) = \delta(q, \epsilon) \\ \hat{\delta}(q, \omega a) & = \cup_{p \in \hat{\delta}(q,\omega)} \epsilon - closure(\delta(p, a)) \end{cases}$$

Definiamo infine il linguaggio accettato dagli ϵ-NFA, il cui automa sarà capace di arrivare a uno stato finale con la chiusura transitiva:

$$L(N) = \{x | \hat{\delta}(q_0, x) \cap F \neq \emptyset\}$$

Chapter 3

Linguaggi regolari

3.1 Operazioni ed espressioni regolari

Esiste un modo alternativo per la descrizione dei linguaggi regolari, ovvero quelli accettati dagli automi a stati finiti. Questi presentano un'algebra di operazioni per poter essere manipolati a partire da un alfabeto Σ sul quale sono definiti.

Unione: Sia Σ un alfabeto e L_1, L_2 insiemi di stringhe di Σ^*; l'unione di L_1, L_2 si definisce:

$$L_1 \cup L_2 = \{x | x \in L_1 \vee x \in L_2\}$$

Concatenazione: Sia Σ un alfabeto e L_1, L_2 insiemi di stringhe di Σ^*; la concatenazione di L_1, L_2 si definisce:

$$L_1 L_2 = \{xy \in \Sigma^* : x \in L_1, y \in L_2\}$$

Inoltre:

$$\begin{cases} \epsilon \in L_1 \implies L_2 \subseteq L_1 L_2 \\ \epsilon \in L_2 \implies L_1 \subseteq L_1 L_2 \end{cases}$$

Stella di Kleene: Sia Σ un alfabeto e L insiemi di stringhe su Σ^*; la chiusura o stella di Kleene si definisce:

$$L^* = \cup_{i \geq 0} L^i; \quad \begin{cases} L^0 = \epsilon \neq \emptyset \\ L^{i+1} = L L^i \end{cases}$$

Mentre la chiusura positiva di L, annotata come L^+, è data dall'insieme

$$L^+ = \cup_{i \geq 1} L^i$$

Si tratta, in altre parole, di una **concatenazione iterativa** di linguaggi. Per esempio, con un linguaggio $L = \{ab\}$, avremmo:

$$\begin{aligned} L^0 &= \{\epsilon\} \\ L^1 &= \{ab\} \cdot \{\epsilon\} = \{ab\} \\ L^2 &= \{ab\} \cdot L^1 = \{ab\} \cdot \{ab\} = \{abab\} \\ L^3 &= \{ab\} \cdot L^2 = \{ab\} \cdot \{abab\} = \{ababab\} \end{aligned} \tag{3.1}$$

Oltre alle operazioni, i linguaggi regolari presentano anche **espressioni**, costrutti simbolici per la loro rappresentazione, definiti tramite induzione. Partendo sempre da un alfabeto Σ, abbiamo:

- $\emptyset$: Espressione regolare che denota il linguaggio vuoto.
- ϵ: Espressione regolare che denota il linguaggio composto solo dalla stringa vuota $\{\epsilon\}$.
- $a \in \Sigma$: Espressione regolare che denota il linguaggio composto dalla stringa di input $\{a\}$.

Date ora r, s due espressioni regolari che rappresentano due linguaggi R, S rispettivamente, abbiamo:

- $r + s$: Espressione regolare che denota l'operazione di unione $R \cup S$.
- rs: Espressione regolare che denota l'operazione di concatenazione $R \cdot S$.
- r^*: Espressione regolare che denota l'operazione di stella di Kleene R^*.

Esiste inoltre un'equivalenza tra DFA ed espressioni regolari, mostrata dal teorema di **McNaughton-Yamada**, il quale afferma che, data un'espressione regolare r, allora esiste un M ϵ-NFA tale che valga $L(M) = L(r)$. Ciò è dimostrabile per induzione sulla complessità strutturale di r. Costruiamo dunque un ϵ-NFA con un solo stato finale; avremo tre casi base:

- Un automa con un singolo stato q_0, corrispondente a quello finale, riconosce il linguaggio $\{\epsilon\}$.
- Un automa con due stati non collegati q_0, q_1, con quest'ultimo quello finale, riconosce il linguaggio $\emptyset$.
- Un automa con due stati collegati q_0, q_1, con quest'ultimo quello finale e raggiungibile leggendo a, riconosce il linguaggio $\{a\}$.

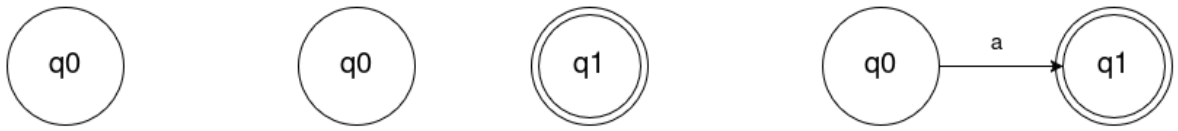


Figure 3.1: Passi base McNaughton-Yamada

Per quanto riguarda i passi induttivi, l'esistenza dei seguenti automi è sempre assicurata dall'ipotesi enunciata. Abbiamo:

- $r = r_1 + r_2$. Per un $i = 1, 2$, indicato come $'$,$''$ nel grafo, sia M_i con stato iniziale q_0^i e stato finale q_f^i l'automa che riconosce $L(r_i)$. Il seguente automa riconosce infatti $L(r) = L(r_1) \cup L(r_2)$:

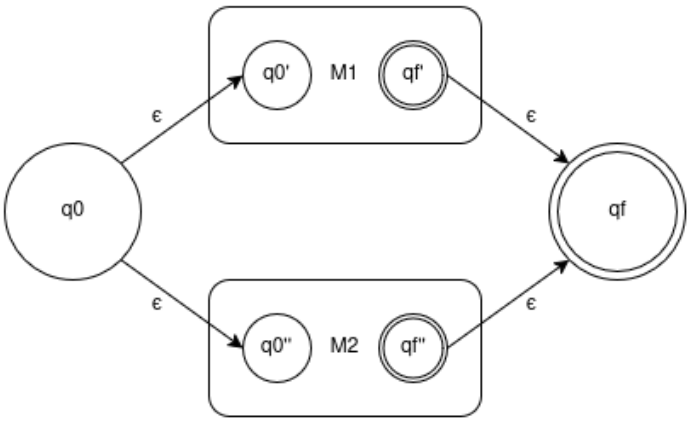


Figure 3.2: Passo induttivo 1 McNaughton-Yamada

- $r = r_1 r_2$. Per un $i = 1, 2$, indicato come $'$,$''$ nel grafo, sia M_i con stato iniziale q_0^i e stato finale q_f^i l'automa che riconosce $L(r_i)$. Il seguente automa riconosce $L(r_1)L(r_2)$:

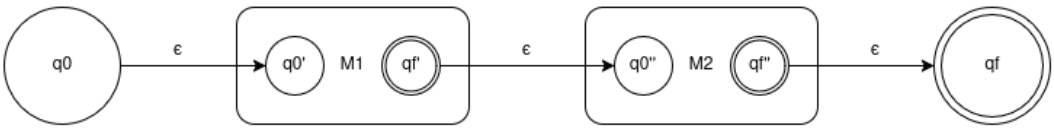


Figure 3.3: Passo induttivo 2 McNaughton-Yamada

- $r = r_1^*$. Sia M_1 con stato iniziale q_0' e stato finale q_f' l'automa che riconosce $L(r_1)$. Il seguente automa riconosce $L(r) = (L(r_1))^*$:

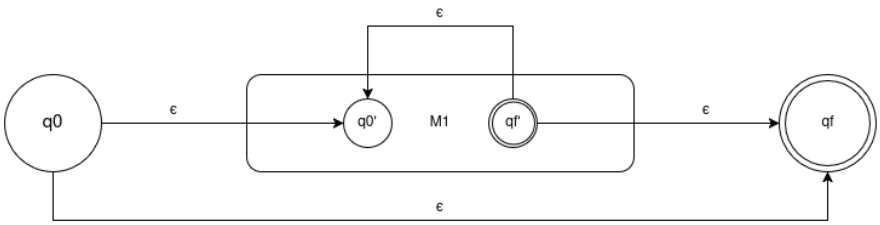


Figure 3.4: Passo induttivo 3 McNaughton-Yamada

3.2 Proprietà principali dei linguaggi regolari

I linguaggi regolari detengono inoltre alcune proprietà fondamentali:

Proprietà di chiusura: I LR sono chiusi rispetto alle operazioni di unione e intersezione finite, stella di Kleene e concatenazione. Dunque, dato un certo numero finito n di linguaggi regolari, valgono:

$$\forall n. L_1 \cup L_2 \cup ... \cup L_n \in REG; \quad L_1 \cap L_2 \cap ... \cap L_n \in REG$$

Come valgono anche:

$$L_1 \cdot L_2 \in REG; \quad L_1^* \in REG$$

La chiusura vale inoltre per la complementazione e quindi anche per le leggi di De Morgan. Dunque:

$$L \in REG \implies \overline{L} = \Sigma^* / L \in REG$$

Proprietà di decidibilità: Determina l'insieme di stringhe accettate da un DFA con n stati. Per esempio:

- $L \neq \emptyset$ è decidibile, perché la relazione vale solamente se esiste un M automa che accetta una stringa x tale che $|x| < |Q|$.
- $|L| = \omega$, un linguaggio infinito, è decidibile perché è tale se e solo se esiste una stringa $x \in L(M)$ tale per cui $n \leq |x| < 2n$, con $n = |Q|$.
- Dati due automi M_1, M_2 tali che $L(M_1) = L(M_2)$, il linguaggio è decidibile.

3.3 Teorema di Myhill-Nerode

Il **Teorema di Myhill-Nerode** è la terza proprietà fondamentale dei linguaggi regolari, la quale afferma l'esistenza dell'automa minimo per ogni linguaggio regolare L, ma

prima di essere introdotto è necessario chiarire alcuni concetti di base legati alla logica matematica.

Dato un insieme S, una **relazione di equivalenza** $R \subseteq S \times S$ induce una partizione di $S = S_1 \cup S_2 \cup ...$, dove per ogni i $S_i \neq \emptyset$ e per ogni $i, j, i \neq j$ valgono:

1. $S_i \cap S_j = \emptyset$.
2. $(\forall a, b \in S_i) aRb$.
3. $(\forall a \in S_i)(\forall b \in S_j) \neq (aRb)$

Le S_i sono **classi di equivalenza**; se $a \in S_i$ usiamo $[a]_R$ per denotare la classe. Se l'insieme S è partizionato in un numero finito di classi, R è l'**indice finito** (k) sull'insieme.

Inoltre, date due relazioni di equivalenza R_1, R_2 sullo stesso insieme S, diciamo che la prima è un **raffinamento** della seconda se ogni S_i della partizione indotta da R_1 è sottoinsieme di equivalenza della partizione indotta da R_2.

Supponiamo adesso un linguaggio $L \subseteq \Sigma^*$ al quale associamo la relazione $R_L \subseteq \Sigma^* \times \Sigma^*$ definita come:

$$xR_Ly \iff (\forall z \in \Sigma^*)(xz \in L \iff yz \in L)$$

Possiamo allo stesso modo associare una relazione $R_M \subseteq \Sigma^* \times \Sigma^*$ a un M DFA, la quale sarà definita come:

$$xR_My \iff \hat{\delta}(q_0, x) = \hat{\delta}(q_0, y)$$

Definiamo in particolare $L_q = \{x \in \Sigma^* : \hat{\delta}(q_0, x) = q\}$ il linguaggio associato allo stato q dell'automa. L'insieme dei linguaggi associati a ogni stato dell'automa sono le classi di equivalenza di R_M.

Diciamo poi che una relazione $R \subseteq \Sigma^* \times \Sigma^*$ è **invariante a destra** (rispetto alla concatenazione) se gode della proprietà:

$$xRy \implies (\forall z \in \Sigma^*)(xzRyz)$$

Dunque, concatenando una qualunque stringa z a x e y elementi dello stesso insieme della partizione, questi rimangono ugualmente in relazione. La stringa z, dunque, non varia la relazione rispetto all'estensione della stringa iniziale verso destra.

Ora possiamo enunciare il teorema di **Myhill-Nerode**, per il quale i seguenti enunciati sono equivalenti:

1. $L \subseteq \Sigma^*$ è riconosciuto da un DFA.
2. L è unione di classi di equivalenza di Σ^* indotte da una relazione di equivalenza invariante a destra e di indice finito.

3. R_L è di indice finito.

Procediamo con la sua dimostrazione:

$1 \to 2$: Sia L accettato da un M DFA; consideriamo la relazione $R = R_M$, la quale abbiamo visto essere invariante a destra. Per questa ragione i vari insiemi:

$$L_q = \{x \in \Sigma^* : \hat{\delta}(q_0, x) = q\}$$

Costituiscono le classi di equivalenza della partizione indotta da R_M.

$2 \to 3$: Vogliamo ora dimostrare che ogni relazione di equivalenza R che soddisfa il secondo punto è un raffinamento di R_L e che quindi la prima abbia un numero di classi maggiore o uguale rispetto ad esso.

Sia $y \in [x]_R$; siccome R è invariante a destra per ipotesi, varrà anche $xzRyz$ per ogni stringa $z \in \Sigma^*$. Dato che L è l'unione delle classi di equivalenza di R, abbiamo che:

$$vRw \implies v \in L \iff w \in L; \quad \text{Di conseguenza:} \forall z \in \Sigma^*, xz \in L \iff yz \in L$$

Ma quindi xR_Ly per definizione e $y \in [x]_{R_L}$. L'indice di R_L è minore o uguale di quello di R, che per ipotesi è finito.

$3 \to 1$: Necessario costruire un DFA M' i cui elementi sono:

- Q': Insieme finito per ipotesi di classi di equivalenza di R_L.
- Σ': Alfabeto uguale a quello di L.
- $\delta'([x], a) = [xa]$
- $q'_0 = [\epsilon]$
- $F' = \{[x] : x \in L\}$

Mostriamo quindi che $L(M') = L$. Anzitutto si verifica per induzione su $|y| \geq 0$ che $\hat{\delta}'([x], y) = [xy]$. Si ha quindi:

$$\hat{\delta}'(q'_0, x) = \hat{\delta}'([\epsilon], x) = [\epsilon x] = [x]$$

E dunque:

$$x \in L(M') \iff \hat{\delta}'(q'_0, x) \iff [x] \in F' \iff x \in L$$

3.4 Pumping lemma per linguaggi regolari

Introduciamo ora una proprietà molto importante e utile per dimostrare quando i linguaggi sono regolari: il **pumping lemma**. Fornisce una condizione Π necessaria alla regolarità dei linguaggi, intuitivamente:

$$L \text{ regolare} \implies \Pi$$

Formalmente, se abbiamo un linguaggio regolare L, allora:

$$\begin{aligned} \Pi : & \exists k \in \mathbb{N}. \\ & \forall z \in L. |z| \geq k \\ & \exists z = uvw. |uv| \leq k \wedge |v| > 0 \\ & \forall i \in \mathbb{N}. uv^i w \in L \end{aligned} \tag{3.2}$$

Fondamentalmente, considerando una qualunque stringa z, afferma che esiste una sua suddivisione in tre parti uvw, per la quale se si ripete i volte quella di mezzo v, il linguaggio rimane ugualmente regolare.

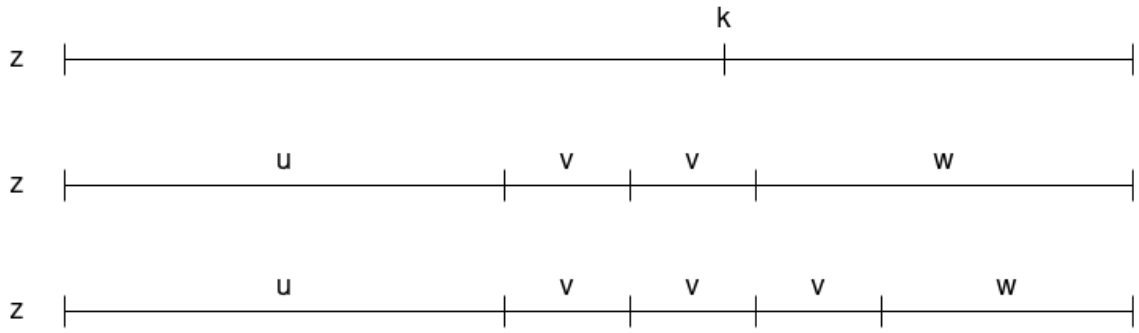


Figure 3.5: Esempio suddivisione Pumping Lemma

Il pumping lemma è utile anche per dimostrare quando un linguaggio non è regolare e rappresenta una condizione sufficiente per tale caratteristica. Basta negare l'intera proprietà:

$$\begin{aligned} \neg\Pi : & \forall k \in \mathbb{N} \\ & \exists z \in L. |z| \geq k \\ & \forall z = uvw. |uv| \leq k \wedge |v| > 0 \\ & \exists i. uv^i w \notin L \end{aligned} \tag{3.3}$$

Per la dimostrazione supponiamo un automa minimo M con stati $Q = \{q_0, q_1, ..., q_n\}$ e un linguaggio regolare $L = L(M)$:

1. $\forall k$: Prendiamo un valore generico k sul quale non deve esserci nessuna condizione. Ciò farà valere la dimostrazione per ogni valore che k può assumere.

2. $\exists z \in L.|z| \geq k$: Scegliamo una stringa $z \in L$ la cui cardinalità è maggiore o uguale di k, dunque:
$$z = a^k b^k \in L; \quad |z| = 2k \geq k$$

3. $\forall z = uvw.|uv| \leq k \wedge |v| > 0$: Creiamo una suddivisione in tre parti dove v non contiene b, perché in tal caso avrebbe lunghezza maggiore di k. Dunque:
$$z = uvw; \quad uv \in a^k$$

4. $\exists i.uv^iw \notin L$: Prendiamo una z_i, siccome la parte ripetuta è compresa solo in a^k consegue che:
$$z_i = uv^iw = a^{k+(i-1)|v|}b^k$$
Riprendendo la condizione di appartenenza ai linguaggi regolari, notiamo che $a^nb^m \in L \iff n = m$, ma con la nostra stringa risulta:
$$\begin{aligned} z_i = a^{k+(i-1)|v|}b^k \in L &\iff k + (i-1)|v| = k \\ &\iff (i-1)|v| = 0 \end{aligned} \tag{3.4}$$
Prendendo $i = 2$, osserviamo $(2-1)|v| = 0 \implies |v| = 0$, che è assurdo, viste le ipotesi sulla suddivisione. La cardinalità della parte ripetuta deve essere maggiore di zero, dunque la stringa z_2 non è accettata dal linguaggio, il quale non sarà regolare.

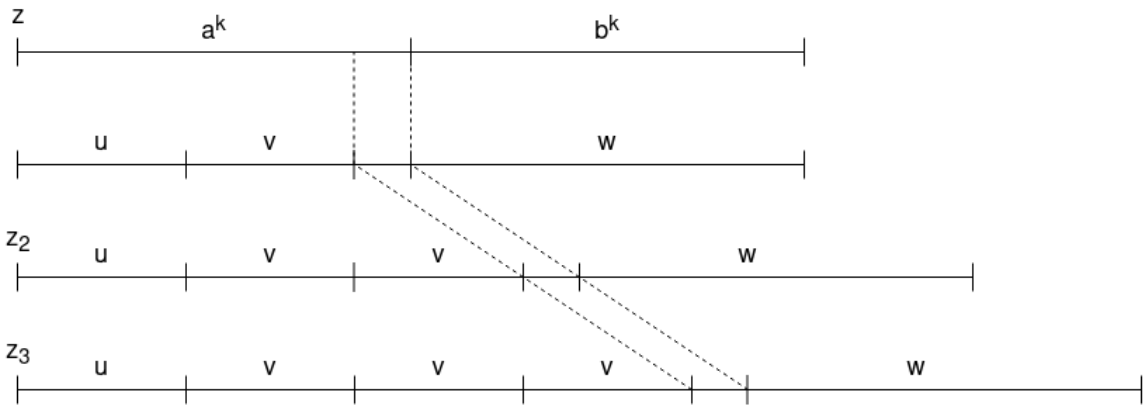


Figure 3.6: Suddivisione delle stringhe z_i

Chapter 4

Linguaggi liberi da contesto

4.1 Linguaggi liberi da contesto, forme normali e automi a pila

4.2 Classificazione di Chomsky

Chapter 5

Teoria della calcolabilità

5.1 Meet and fuck kingdom, steve

5.2 Meet 'n HUH!?